MOWNIT Laboratorium 5

Aproksymacja

Autor: Jakub Staniszewski, Jacek Łoboda

Data: 14.04.2026

Zadanie 1

Opis problemu

Celem zadania jest przeprowadzenie punktowej aproksymacji średniokwadratowej populacji Stanów Zjednoczonych na podstawie danych historycznych z lat 1900–1980. Aproksymację wykonano za pomocą wielomianów algebraicznych stopnia m, gdzie $0 \leq m \leq 6$.

Następnie zbadano zdolności predykcyjne wyznaczonych modeli poprzez ekstrapolację wielomianów do roku 1990 i porównanie uzyskanych wyników z rzeczywistą wartością populacji w tym roku, która wynosiła 248 709 873 osób. Wybór optymalnego stopnia wielomianu przeanalizowano na dwa sposoby: poprzez analizę błędu względnego dla pojedynczego punktu w przyszłości (1990 r.) oraz przy użyciu kryterium informacyjnego Akaikego (AIC).

Wyniki ekstrapolacji

W poniższej tabeli zestawiono wyniki przewidywań populacji na rok 1990 wygenerowane przez modele wielomianowe rzędu od 0 do 6 wraz z wartością błędu względnego w stosunku do populacji rzeczywistej.

Stopień wielomianu (m)	Wartość ekstrapolowana	Błąd względny
0	143 369 177	0.424
1	235 808 109	0.052
2	254 712 945	0.024

Stopień wielomianu (m)	Wartość ekstrapolowana	Błąd względny
3	261 439 111	0.051
4	251 719 345	0.012
5	263 442 928	0.059
6	265 700 975	0.068

Analiza błędów

Błąd względny dla punktu poddanego ekstrapolacji (1990 rok) wykazuje zauważalną zmienność. Najmniej dokładny model to, zgodnie z oczekiwaniami, wielomian stopnia zerowego (stała), ze względu na to, że populacja ma silny trend rosnący. Najdokładniejszy wynik w punkcie 1990 dał wielomian stopnia 4, dla którego błąd względny wyniósł zaledwie 0.012 (około 1.2%). Warto zauważyć, że modele o najwyższych stopniach (5 i 6) generują gorsze prognozy niż model czwartego, czy nawet drugiego stopnia, co sugeruje problem z nadmiernym dopasowaniem (overfittingiem).

Kryterium Akaikego

Problem wyboru optymalnego stopnia wielomianu sprowadza się do znalezienia balansu pomiędzy zjawiskiem obciążenia (zbyt niski stopień i ignorowanie trendu danych) a wariancji (zbyt wysoki stopień uwzględniający szum w danych). Oceny globalnej jakości dopasowania modelu, karzącej go jednocześnie za nadmiarową złożoność, dokonuje się używając kryterium informacyjnego Akaikego (AIC).

Standardowy wzór AIC wyraża się jako:

$$AIC = 2k + n \ln \left(\frac{\sum_{i=1}^{n} [y_i - \hat{y}(x_i)]^2}{n} \right)$$

Gdzie:

- n to liczba obserwacji (w naszym przypadku $n = 9$),
- k to liczba parametrów modelu (dla wielomianu stopnia m wynosi ona $k = m + 1$),
- y_i to prawdziwa liczba osób,
- $\hat{y}(x_i)$ to wartość przewidywana przez model aproksymacyjny.

Ze względu na to, że rozmiar próbki jest bardzo mały w stosunku do liczby estymowanych parametrów ($\frac{n}{k} < 40$), należało użyć wersji kryterium z członem korygującym (AIC_c):

$$AIC_c = AIC + \frac{2k(k+1)}{n-k-1}$$

Wartości poprawionego kryterium AIC_c zestawiono w poniższej tabeli:

Stopień wielomianu (m)	AIC_c
0	320.884
1	288.556
2	278.082
3	281.547
4	284.672
5	300.868
6	320.208

Interpretacja: Im mniejsza wartość kryterium AIC_c, tym lepszy – w ujęciu teorii informacji – jest badany model. Analiza wartości wskazuje wyraźne minimum dla wielomianu stopnia $m = 2$.

Porównanie modeli

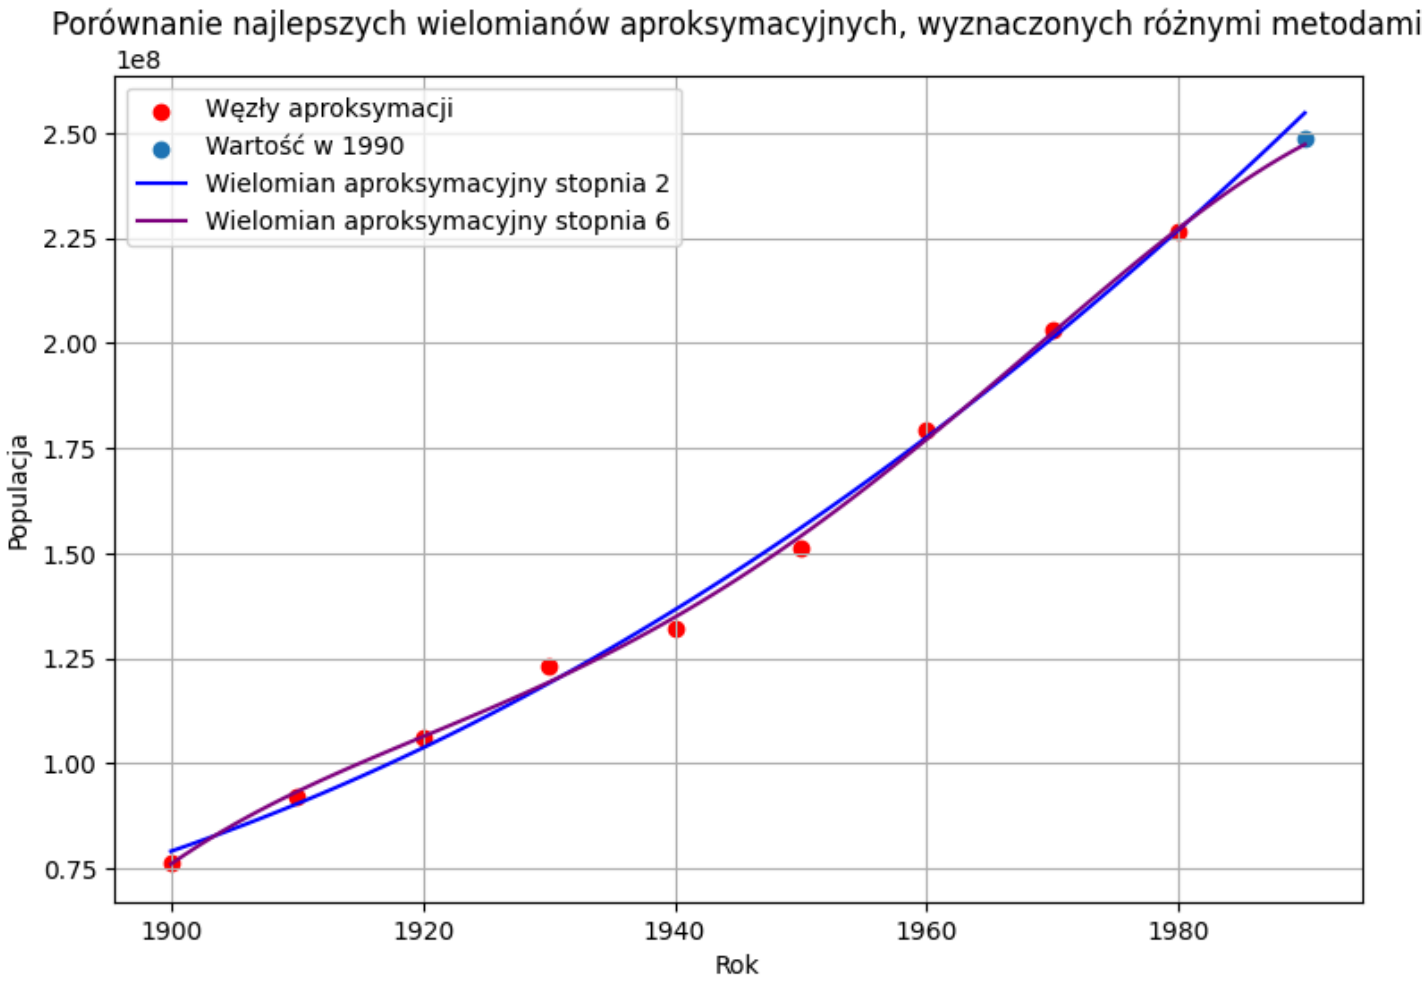

Rysunek 1: Porównanie przebiegu najlepszych wielomianów aproksymacyjnych, wyznaczonych na podstawie analizy błędu ekstrapolacji w jednym punkcie ($m = 4$) oraz kryterium Akaikego ($m = 2$).

Wnioski

Stopień wielomianu wybrany na podstawie wskaźnika AIC_c ($m = 2$) nie pokrywa się ze stopniem modelu, który wygenerował najmniejszy błąd punktowy zjawiska ekstrapolacji ($m = 4$). Taka rozbieżność jest zjawiskiem w pełni naturalnym i uzasadnionym teoretycznie:

1. **Ekstrapolacja punktowa** w roku 1990 ma charakter weryfikacji lokalnej. Fakt, że krzywa wielomianu 4. stopnia przeszła bliżej jednej konkretnej wartości referencyjnej, jest w pewnym stopniu koincydencją wynikającą z zachowania ogona tego konkretnego wielomianu poza przedziałem aproksymacji.
2. **Kryterium** AIC_c dokonuje oceny globalnej. Równoważy ono błąd dopasowania do znanych punktów na przedziale bazowym z "karą" za wprowadzanie nadmiarowych stopni swobody.

3. Z punktu widzenia bezpieczeństwa modelowania statystycznego i fizycznego sensu danych (wzrost populacji jest procesem stosunkowo płynnym), użycie wielomianu wyższego rzędu (np. $m = 4$ lub wyżej) stwarza ogromne ryzyko gwałtownych oscylacji poza obszarem modelowania. Model kwadratowy ($m = 2$) jest modelem znacznie bardziej stabilnym, odpornym na losowy szum i lepiej oddającym długoterminowy, rosnący trend w badanych danych populacyjnych.

W ogólnym ujęciu, jako model referencyjny należy zawsze wskazywać ten wyznaczony metodą analityczną karzącą za złożoność (Kryterium Akaikego).

Zadanie 2

Opis problemu

Zadanie polegało na przeprowadzeniu ciągłej aproksymacji średniokwadratowej dla nieliniowej funkcji $f(x) = \sqrt{x}$ w przedziale bazowym $[0, 2]$. Ze względu na uwarunkowania numeryczne, jako bazy aproksymacyjnej użyto ortogonalnych wielomianów Czebyszewa pierwszego rodzaju do drugiego stopnia włącznie. Podejście to stanowi efektywną i tańszą obliczeniowo alternatywę dla aproksymacji jednostajnej (optymalnej wg kryterium minimaksowego).

Funkcja wagowa

Wielomiany Czebyszewa są naturalnie definiowane dla przedziału $[-1, 1]$. Aby zastosować je do naszej docelowej dziedziny $x \in [0, 2]$, dokonano transformacji zmiennej poprzez proste podstawienie liniowe:

$$t = x - 1$$

co po przekształceniu powrotnym gwarantuje zachowanie odpowiednich przedziałów. Do budowy iloczynu skalarnego wielomianów Czebyszewa wykorzystuje się funkcję wagową postaci:

$$w(t) = \frac{1}{\sqrt{1 - t^2}}$$

Wielomiany Czebyszewa

Trzy pierwsze wielomiany Czebyszewa ($n = 0, 1, 2$) wykorzystane jako baza analityczna dla aproksymacji ciągłej przyjmują postać:

- $T_0(t) = 1$
- $T_1(t) = t$
- $T_2(t) = 2t^2 - 1$

Aproksymacja

Współczynniki rozwinięcia c_i w bazie Czebyszewa minimalizujące błąd średniokwadratowy obliczane są z wykorzystaniem standardowego iloczynu skalarnego z zadaną wyżej funkcją wagową $w(t)$:

$$c_i = \frac{\langle f, T_i \rangle}{\langle T_i, T_i \rangle} = \frac{\int_{-1}^{1} w(t) f(t+1) T_i(t) dt}{\int_{-1}^{1} w(t) T_i^2(t) dt}$$

Normy kwadratowe dla tych wielomianów (mianowniki równań) są wartościami ściśle zdefiniowanymi:

- dla $i = 0$ wynoszą π,
- dla $i > 0$ wynoszą $\frac{\pi}{2}$.

Ostatecznie badana funkcja zostaje przybliżona sumą:

$$\hat{f}(x) = \sum_{i=0}^{2} c_i T_i(x-1)$$

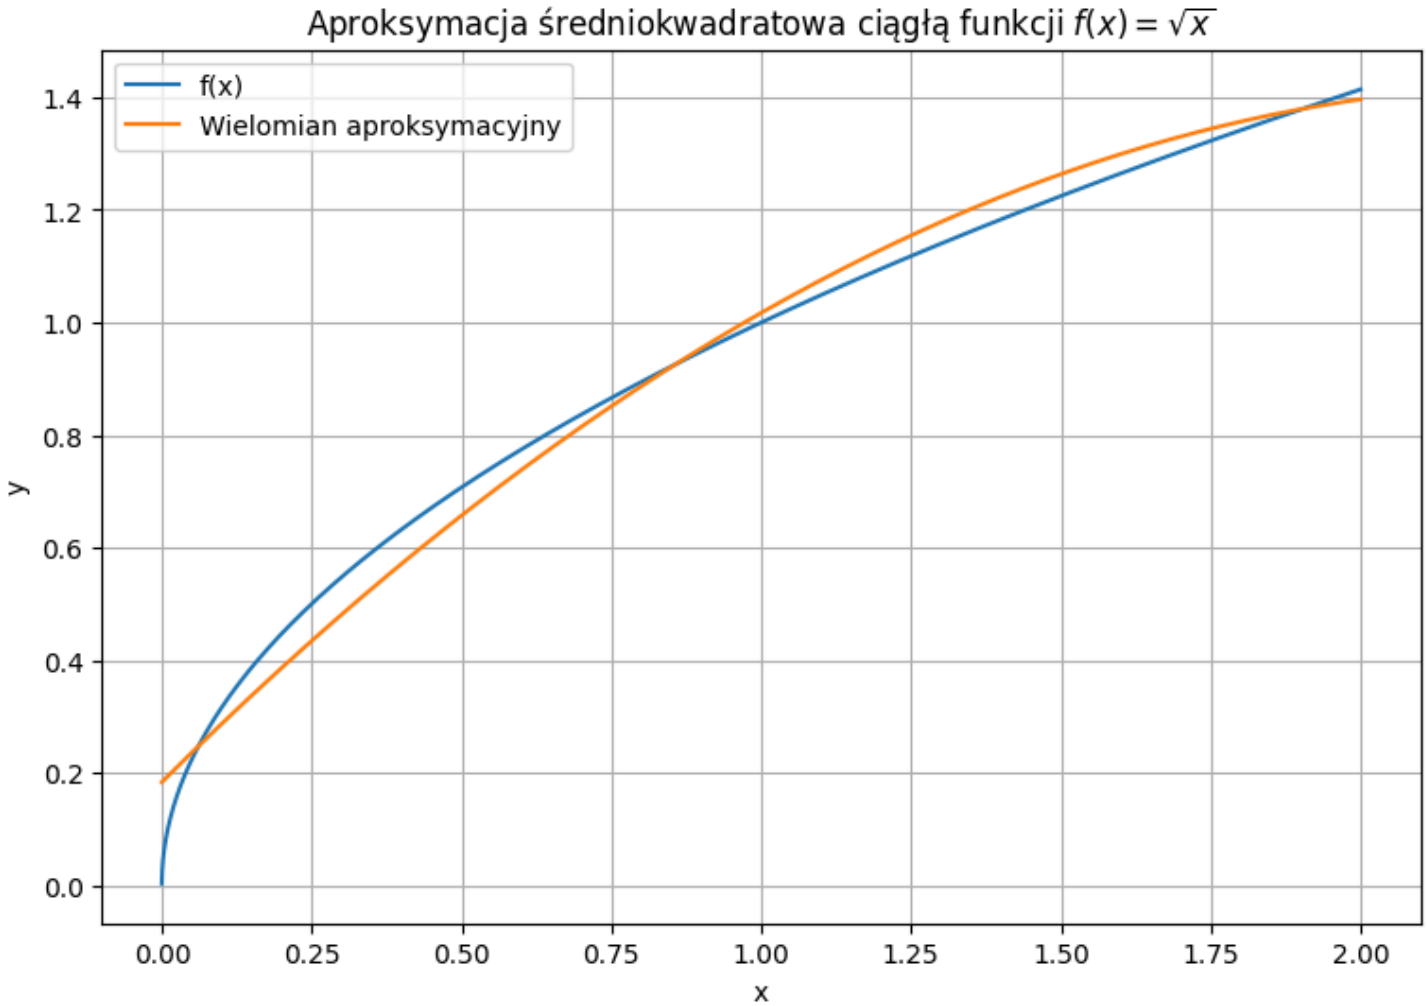

Rysunek 2: Porównanie przebiegu funkcji oryginalnej $f(x) = \sqrt{x}$ oraz uzyskanego wielomianu aproksymacyjnego z bazy Czebyszewa.

Wnioski

Na podstawie wygenerowanego wykresu i przebiegu funkcji można stwierdzić, że wyznaczony analitycznie wielomian niezwykle precyzyjnie aproksymuje funkcję $f(x) = \sqrt{x}$ na przeważającej części przedziału dziedziny.

Jedyne widoczne – i matematycznie spodziewane – odchylenie zachodzi w bezpośrednim sąsiedztwie lewego brzegu przedziału (w okolicach $x = 0$). Zjawisko to wynika bezpośrednio z natury analitycznej samej badanej funkcji: pierwsza pochodna funkcji pierwiastkowej w zerze dąży do nieskończoności (asymptota pionowa stycznej), z kolei wielomiany algebraiczne zawsze charakteryzują się skończonymi wartościami pochodnych. Mimo tej fundamentalnej rozbieżności krzywizn w punkcie zerowym, zastosowanie ciągłej bazy wielomianów Czebyszewa 2. stopnia zagwarantowało znakomite i "spłaszczone" rozłożenie maksymalnego błędu przybliżenia wzdłuż analizowanego obszaru bez negatywnego powstawania oscylacji widocznych w bazach standardowych (jak na przykład w wielomianach Taylora).

Źródła

1. Instrukcje do laboratorium `lab5.pdf` .
2. Wikipedia